

test_mathou

31/03/2026

Contents

1	Analyse Factorielle des Données Mixtes (AFMD)	2
1.1	Cadre méthodologique	2
1.2	Interprétation des axes	2
2	Classification Ascendante Hiérarchique (HCPC)	3
2.1	Détermination du nombre de clusters	3
2.2	Construction des clusters	4
2.3	Interprétation économique et lien avec le risque	5
3	Modélisation Prédictive Supervisée	6
3.1	Rééquilibrage des classes (SMOTE)	6
3.2	Régression Logistique (GLM)	6
3.3	CART	8
3.4	Random Forest	10
3.5	Adaboost	11
3.6	Lasso	13
3.7	LDA	15
3.8	QDA	15
3.9	Comparaison	15
4	Annexes	18
4.1	Courbes ROC par méthode	18

Introduction

Ce projet s'appuie sur le jeu de données German Credit, qui regroupe des informations relatives à des emprunteurs, incluant à la fois des variables quantitatives (montant du crédit, durée, âge) et qualitatives (historique de crédit, statut du compte, situation professionnelle). L'objectif principal est d'analyser le risque de défaut bancaire et de construire des modèles capables de prédire ce risque de manière fiable. Dans un premier temps, nous allons réaliser une analyse des données mixtes à l'aide de l'AFMD, afin de résumer l'information et d'identifier les principales dimensions structurant les profils. Cette étape sera complétée par une classification non supervisée pour mettre en évidence des groupes homogènes d'emprunteurs. Dans un second temps, plusieurs modèles de classification supervisée seront développés et comparés (régression logistique, arbres de décision, méthodes d'ensemble, etc.) dans le but d'évaluer leur capacité à prédire le défaut. L'ensemble de ces approches permettra à la fois de mieux comprendre les facteurs de risque et de proposer des outils d'aide à la décision dans un contexte bancaire.

1 Analyse Factorielle des Données Mixtes (AFMD)

1.1 Cadre méthodologique

Le jeu de données étudié comporte à la fois des variables quantitatives et qualitatives. Il est donc nécessaire d'utiliser une méthode adaptée aux données mixtes. L'Analyse Factorielle des Données Mixtes (AFMD) permet de combiner les principes de l'Analyse en Composantes Principales (ACP) et de l'Analyse des Correspondances Multiples (ACM), afin de projeter les individus dans un espace de dimension réduite.



L'objectif est double : résumer l'information contenue dans les variables initiales tout en conservant un maximum d'inertie, et identifier les variables les plus discriminantes dans l'explication du risque de défaut bancaire.

##	eigenvalue	percentage of variance	cumulative percentage of variance
## comp 1	3.259349	6.651733	6.651733
## comp 2	2.359822	4.815963	11.467696
## comp 3	2.002668	4.087078	15.554774
## comp 4	1.736539	3.543958	19.098731
## comp 5	1.638856	3.344604	22.443335

L'Analyse Factorielle des Données Mixtes (AFMD) est très pertinente ici, car le jeu de données contient à la fois des variables quantitatives (montant, durée) et qualitatives (statut du compte, type de logement). On obtient une inertie très faible en effet les deux premiers axes ne capturent que 11,5 % de l'information (variance). Mathématiquement, c'est faible, mais économiquement, c'est un résultat classique. Cela démontre que le risque de défaut ne dépend pas d'un ou deux facteurs isolés (comme juste le salaire ou juste l'âge), mais qu'il est multifactoriel et dilué à travers de nombreux critères.

1.2 Interprétation des axes

L'interprétation des axes repose sur l'analyse des contributions des variables.




L'Axe 1 ("L'engagement financier") : Cet axe sépare les clients selon leur patrimoine (logement, propriété) et les caractéristiques de leur emprunt (montant et durée). L'Axe 2 ("La solvabilité et stabilité") : C'est l'axe qui capte la santé financière, basée sur l'historique de crédit, le compte courant et l'ancienneté au travail. Fait intéressant, le défaut de paiement s'aligne sur cet axe, prouvant que le passé financier (historique) est le meilleur indicateur de la santé financière future. De plus le chevauchement des profils sur le graphique montre qu'une simple séparation linéaire est impossible. Les "bons" et "mauvais" payeurs se ressemblent beaucoup.

2 Classification Ascendante Hiérarchique (HCPC)

2.1 Détermination du nombre de clusters

Afin de déterminer le nombre optimal de groupes, la méthode du coude est appliquée sur les coordonnées factorielles issues de l'AFMD.


Méthode du coude



Le graphique ne met pas en évidence de coude clair dans la courbe de l'inertie. Cela montre qu'on ne peut pas séparer clairement les individus en classes distinctes. Néanmoins, un changement dans la vitesse de décroissance se dessine autour de 6 groupes. Ce choix correspond à un compromis entre réduction de l'inertie intra-classe et lisibilité de la segmentation.

2.2 Construction des clusters

```
##
##  1  2  3  4  5  6
## 282 167 246 152 53 100
```



##	0	1	% Défaut
## 1	156	126	44.7
## 2	131	36	21.6
## 3	242	4	1.6
## 4	88	64	42.1
## 5	34	19	35.8
## 6	49	51	51.0

2.3 Interprétation économique et lien avec le risque

L'analyse réalisée à partir de la classification hiérarchique sur composantes principales met en évidence 6 segments distincts au sein de la clientèle. Ces groupes présentent des niveaux de risque très contrastés, avec des taux de défaut qui varient fortement, allant de 1,6 % pour les profils les plus fiables jusqu'à 51 % pour les situations les plus critiques. Cette dispersion traduit une forte hétérogénéité dans les comportements de remboursement et dans les profils socio-économiques des clients.

Le segment le plus sécurisé correspond au cluster 3, qui affiche un taux de défaut particulièrement faible de 1,6 %. Les individus qui le composent se distinguent par une situation financière stable, notamment par l'absence de découvert. Ils sont également plus âgés que la moyenne, avec un âge moyen de 38,5 ans contre 35,5 ans pour l'ensemble de l'échantillon. De plus, ils possèdent une certaine stabilité professionnelle, avec une ancienneté souvent supérieure à 7 ans. Ces clients empruntent en moyenne 2606 € sur des durées relativement faibles.

À l'opposé, le cluster 6 représente le segment le plus risqué avec un taux de défaut de 51 %. Les clients de ce groupe présentent des signes de fragilité importants, notamment une absence quasi totale de patrimoine. Beaucoup sont logés gratuitement et ne possèdent aucun bien. Malgré un âge moyen relativement élevé de

43,7 ans, ils empruntent parmi les montants les plus élevés, avec une moyenne autour de 4993 €, soit plus de 50 % au-dessus de la moyenne, avec des durées de remboursement proches de 29 mois.

Les clusters 1 et 4 regroupent des profils à risque intermédiaire mais pour des raisons différentes. Le cluster 1, avec un taux de défaut de 44,7 %, est principalement composé de jeunes clients dont l'âge moyen est de 28,3 ans. Les montants empruntés sont relativement faibles, autour de 2185 €. L'absence d'historique solide semble être le principal facteur expliquant leur niveau de risque. De son côté, le cluster 4 présente un taux de défaut de 42,1 % et se caractérise par des montants empruntés très élevés, en moyenne 6050 €, ainsi que des durées longues proches de 33 mois.

Enfin, les clusters 2 et 5 correspondent à des profils plus modérés. Le cluster 2 affiche un taux de défaut de 21,6 % et regroupe des clients plus âgés, autour de 39,4 ans. Ces derniers empruntent des montants faibles, en moyenne 1857 €, sur des durées courtes de 13 mois. Le cluster 5 présente un taux de défaut plus élevé, à 35,8 %, avec des montants importants proches de 5375 €, mais des clients plus âgés, autour de 40,7 ans, et des charges de remboursement mieux adaptées à leurs revenus, ce qui permet de contenir partiellement le risque.

Dans l'ensemble, cette segmentation met en évidence des logiques de risque différentes selon les profils, combinant à la fois l'âge, la stabilité professionnelle, le niveau d'endettement et la capacité financière.

3 Modélisation Prédicative Supervisée

3.1 Rééquilibrage des classes (SMOTE)

L'échantillon initial présente un déséquilibre marqué entre les classes : 574 clients sains contre 226 clients à risque. La technique SMOTE (Synthetic Minority Over-sampling Technique) est utilisée afin de générer des observations synthétiques pour la classe minoritaire. Elle conduit à un échantillon d'entraînement de 1582 individus, répartis de manière quasi équilibrée (904 sains contre 678 à risque).

3.2 Régression Logistique (GLM)

```
resultats_logit = display_results(class_logit, data.test)
```

```
##          Réalité
## Prédiction  0    1
##           0 117  22
##           1  29  32
## Accuracy : 0.745
## Erreur globale : 0.255
## Sensibilité (Classe 1 ) : 0.593
## Spécificité (Classe 0 ) : 0.801
```

```
accuracy_logit <- resultats_logit[1]
err_logit      <- resultats_logit[2]
sensi_logit    <- resultats_logit[3]
speci_logit    <- resultats_logit[4]

ROC_logit <- roc(data.test$Credit_risk, pred_logit)
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

```
ROC_logit$auc
```

```
## Area under the curve: 0.776
```

Le modèle identifie trois variables comme étant nécessaires pour évaluer la capacité de défaut bancaire (p -value < 0,001). Le statut personnel et le sexe (Personal_status_sex) apparaissent comme la variable la plus influente du modèle ($z = -12,05$). Le coefficient fortement négatif (-5,89) indique que certaines catégories présentent une probabilité de défaut nettement plus faible que les autres.

Le taux d'endettement (Installment_rate_percentage_income) présente un coefficient négatif de -0,95. Cela veut dire que ce n'est pas une variable qui permet de prédire efficacement si une personne va faire un défaut bancaire ou non.

L'âge (Age_in_years), avec un coefficient de -1,52 ($z = -2,43$), montre que l'augmentation de l'âge est associée à une diminution de la probabilité de défaut, ce qui met en évidence un effet de maturité dans les comportements observés.


L'analyse des coefficients estimés permet ensuite d'identifier les variables associées à une augmentation ou à une diminution du risque. Parmi les facteurs qui augmentent le risque, le nombre de personnes à charge (Number_people_liable) présente un coefficient élevé de +4,22, ce qui en fait l'un des prédicteurs les plus marquants du modèle. La présence d'un téléphone (Telephone) est également associée à une augmentation du risque avec un coefficient de +5,17. Le statut du compte courant contribue aussi positivement au risque, avec un coefficient de +0,33, traduisant une dégradation progressive vers la classe risquée.

À l'inverse, certains facteurs sont associés à une réduction du risque. L'ancienneté dans l'emploi (Present_employment_since) présente un coefficient de -0,72, ce qui confirme l'importance de la stabilité professionnelle. La durée du crédit (Duration_in_month) est également associée à un coefficient légèrement négatif (-0,03), ce qui suggère que les durées plus longues sont liées à des profils plus stables.

Par rapport à une approche exploratoire comme le clustering, ce modèle permet de quantifier précisément l'effet de chaque variable et d'obtenir une lecture plus fine.

Le modèle de régression logistique présente une performance modeste mais cohérente avec le domaine du risque de crédit, atteignant une accuracy de 74,5% et une AUC de 0,776. L'analyse des coefficients (et le processus d'élimination AIC) met en évidence que les variables les plus discriminantes sont de véritables indicateurs financiers et de profil : le statut du compte courant, l'historique de crédit, la durée du prêt, ainsi que des critères liés à la propriété et à la situation matrimoniale. L'erreur globale est de 25,5%, mais on note que le modèle peine particulièrement à identifier les mauvais payeurs (Erreur classe 1 de près de 41%), classant trop de clients à risque comme étant de "bons crédits".

3.3 CART




```
##
## Classification tree:
## rpart(formula = Credit_risk ~ ., data = data.train.balanced,
##       method = "class", model = TRUE, control = rpart.control(minsplit = 15,
##       ))
##
## Variables actually used in tree construction:
## [1] Duration_in_month          Other_installment_plans
## [3] Present_employment_since   Present_residence_since
## [5] Property                   Purpose
## [7] Status_of_existing_checking_account
##
## Root node error: 738/1722 = 0.42857
##
## n= 1722
##
##      CP nsplit rel error  xerror   xstd
## 1 0.178862     0  1.00000 1.00000 0.027826
## 2 0.135501     1  0.82114 0.82114 0.026853
## 3 0.039295     2  0.68564 0.68564 0.025614
## 4 0.027100     3  0.64634 0.66667 0.025402
## 5 0.017615     5  0.59214 0.63008 0.024964
## 6 0.013550     7  0.55691 0.59350 0.024488
## 7 0.010840     8  0.54336 0.58401 0.024357
```



```
## 8 0.010000      10      0.52168 0.57182 0.024185
```

```
## [1] "CP optimal : 0.01"
```

Arbre CART Credit Risk



```
##          Réalité
## Prédiction  0   1
##           0 109  24
##           1  37  30
## Accuracy : 0.695
## Erreur globale : 0.305
## Sensibilité (Classe 1) : 0.556
## Spécificité (Classe 0) : 0.747

## Setting levels: control = 0, case = 1


## Setting direction: controls < cases

## Area under the curve: 0.7128
```

L'arbre CART optimisé (cp = 0.01) présente une performance plus faible que la régression logistique, avec une accuracy de 69,5% et une AUC de 0,713. L'arbre s'est construit principalement autour des variables concernant le logement, l'état du compte courant et la situation professionnelle. Son taux d'erreur sur la détection des mauvais payeurs (44,4%) est plus élevé que celui de la régression logistique. Son taux d'erreur sur la détection des mauvais payeurs est de 44,4 %, ce qui est élevé. En termes de faux positifs, le modèle classe 37 clients à risque comme étant solvables, ce qui correspond à une part importante des individus risqués mal identifiés. Cela signifie concrètement que le modèle accorde trop de crédits à des profils qui vont faire défaut. Dans l'ensemble, ce modèle reste trop simplifié et peu fiable pour une gestion du risque.

3.4 Random Forest

```
##
## Call:
## randomForest(formula = Credit_risk ~ ., data = data.train.balanced)
##           Type of random forest: classification
##           Number of trees: 500
## No. of variables tried at each split: 4
##
##           OOB estimate of  error rate: 7.72%
## Confusion matrix:
##      0   1 class.error
## 0 945  39 0.03963415
## 1   94 644 0.12737127
```



```
##           Réalité
## Prédiction  0   1
##           0 115 22
##           1  31 32
## Accuracy : 0.735
## Erreur globale : 0.265
## Sensibilité (Classe 1 ) : 0.593
## Spécificité (Classe 0 ) : 0.788

## Setting levels: control = 0, case = 1
```


```
## Setting direction: controls < cases
```

```
## Area under the curve: 0.7638
```

La Random Forest améliore les performances avec une accuracy de 73,5 % et une AUC de 0,764. L'erreur sur les mauvais payeurs descend à 40,7 %, ce qui montre un gain par rapport au CART. En revanche, le nombre de faux positifs reste élevé avec 31 clients à risque classés comme solvables. Même si la méthode réduit la variance en agrégeant plusieurs arbres, elle ne corrige pas complètement le problème principal qui est la mauvaise détection des profils risqués. Le modèle reste donc encore exposé à des erreurs coûteuses en termes d'octroi de crédit.

3.5 Adaboost

Nous allons maintenant utiliser l'algorithme Adaboost avec 5 plis de cross-validation.




```
## Nombre d'arbres optimal : 4993
```

```
## Réalité
## Prédiction  0  1
##           0 126 31
##           1  20 23
## Accuracy : 0.745
## Erreur globale : 0.255
## Sensibilité (Classe 1 ) : 0.426
## Spécificité (Classe 0 ) : 0.863
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

```
## Area under the curve: 0.7633
```



```
##
##                                     var
## Number_existing_credits_bank      Number_existing_credits_bank
## Present_residence_since            Present_residence_since
## Status_of_existing_checking_account Status_of_existing_checking_account
## Duration_in_month                  Duration_in_month
## Purpose                            Purpose
## Installment_rate_percentage_income Installment_rate_percentage_income
## Age_in_years                       Age_in_years
## Credit_history                     Credit_history
## Credit_amount                      Credit_amount
## Other_installment_plans            Other_installment_plans
## Housing                            Housing
## Savings_account_bonds              Savings_account_bonds
## Present_employment_since            Present_employment_since
## Number_people_liable               Number_people_liable
## Property                           Property
## Personal_status_sex                Personal_status_sex
## Job                                Job
## Other_debtors_guarantors           Other_debtors_guarantors
```

		Telephone
		Foreign_worker
##	rel.inf	
## Number_existing_credits_bank	15.92837452	
## Present_residence_since	11.78635497	
## Status_of_existing_checking_account	11.62196236	
## Duration_in_month	10.66239231	
## Purpose	7.58866775	
## Installment_rate_percentage_income	6.87305334	
## Age_in_years	6.71155148	
## Credit_history	4.47683793	
## Credit_amount	4.34416493	
## Other_installment_plans	4.29235248	
## Housing	3.55607876	
## Savings_account_bonds	2.68152190	
## Present_employment_since	2.58398093	
## Number_people_liable	1.74060578	
## Property	1.41142819	
## Personal_status_sex	1.21336353	
## Job	1.17173367	
## Other_debtors_guarantors	0.78624373	
## Telephone	0.52061533	
## Foreign_worker	0.04871611	


Le modèle Adaboost présente une accuracy de 74,5 % et une AUC de 0,763, ce qui est comparable aux autres modèles. Cependant, sa sensibilité est faible (42,6 %), ce qui se traduit par une très mauvaise détection des mauvais payeurs. Il produit 20 faux positifs, ce qui peut sembler plus faible en valeur absolue, mais cela s'explique surtout par le fait qu'il identifie très peu de profils risqués au global. Autrement dit, il "évite" les faux positifs en ne détectant pas correctement la classe à risque. Ce comportement traduit un biais vers la classe majoritaire et limite fortement son intérêt opérationnel.

3.6 Lasso

Le chargement a nécessité le package : Matrix

Loaded glmnet 4.1-10

[1] 0.001481308



```
##          Réalité
## Prédiction  0   1
##           0 118  21
##           1  28  33
## Accuracy : 0.755
## Erreur globale : 0.245
## Sensibilité (Classe 1 ) : 0.611
## Spécificité (Classe 0 ) : 0.808

## Setting levels: control = 0, case = 1

## Warning in roc.default(data.test$Credit_risk, prob_lasso): Deprecated use a
## matrix as predictor. Unexpected results may be produced, please pass a numeric
## vector.

## Setting direction: controls < cases

## Area under the curve: 0.7809
```

La régression Lasso s'impose comme le modèle le plus équilibré et légèrement supérieur sur ce jeu de données corrigé, avec la meilleure Accuracy (75,5%) et la meilleure AUC (0,781). Le graphique du chemin de régularisation montre que le modèle sélectionne efficacement un sous-ensemble pertinent de variables avant de commencer à écraser les coefficients, ce qui réduit le bruit sans perdre les signaux importants. Son taux d'erreur sur les mauvais payeurs (38,9%) est d'ailleurs le plus faible parmi tous les modèles testés, faisant du Lasso le meilleur candidat pour minimiser le risque financier tout en conservant une bonne interprétabilité.

3.7 LDA

```
##          Réalité
## Prédiction  0   1
##           0 120 22
##           1  26 32
## Accuracy : 0.76
## Erreur globale : 0.24
## Sensibilité (Classe 1 ) : 0.593
## Spécificité (Classe 0 ) : 0.822

## Setting levels: control = 0, case = 1

## Setting direction: controls < cases

## Area under the curve: 0.7768
```

L'analyse discriminante linéaire (LDA) présente la meilleure accuracy globale, autour de 76 %, mais avec une AUC légèrement inférieure au LASSO. Elle est performante pour classer les clients solvables, mais reste moins efficace pour détecter les profils à risque. Cela se traduit par un nombre de faux positifs encore significatif, ce qui pose problème dans un contexte bancaire. Le modèle suppose une structure des données assez stricte, ce qui limite sa capacité à bien séparer les cas ambigus.


3.8 QDA

On ne peut pas effectuer une QDA classique sur notre jeu de données actuel.


3.9 Comparaison

##	Methode	Accuracy	Erreur_totale	sensi	speci
## 1	GLM	0.745	0.255	0.5925926	0.8013699
## 2	CART	0.695	0.305	0.5555556	0.7465753
## 3	Random Forest	0.735	0.265	0.5925926	0.7876712
## 4	Adaboost	0.745	0.255	0.4259259	0.8630137
## 5	Lasso	0.755	0.245	0.6111111	0.8082192
## 6	LDA	0.760	0.240	0.5925926	0.8219178

Comparaison des Accuracy



Comparaison des Erreurs par Classe



L'analyse comparative des différents modèles de classification met en évidence des performances globalement proches en termes d'accuracy, comprises entre 69,5 % pour l'arbre CART et 76,0 % pour la LDA. Les valeurs d'AUC suivent la même tendance, variant de 0,713 à 0,781. Toutefois, dans un contexte de risque de crédit, ces indicateurs globaux ne suffisent pas à évaluer la pertinence d'un modèle. L'enjeu principal réside dans la capacité à limiter les erreurs critiques, c'est-à-dire les cas où un client à risque est classé comme solvable. Ce type d'erreur correspond à l'octroi d'un crédit à un individu qui fera défaut, ce qui constitue le coût le plus élevé pour l'établissement bancaire.

La régression logistique constitue un point de référence solide. Avec une accuracy de 74,5 % et une AUC de 0,776, elle offre un bon compromis global. Cependant, elle présente une sensibilité de 59,3 %, ce qui signifie qu'environ 40,7 % des clients à risque ne sont pas détectés. Concrètement, cela se traduit par 22 clients à risque classés comme solvables. Ce niveau d'erreur reste significatif et montre que, malgré sa stabilité, le modèle peine à sécuriser totalement l'octroi de crédit.

L'arbre CART apparaît comme le modèle le moins performant. Son accuracy de 69,5 % et son AUC de 0,713 traduisent une capacité de discrimination limitée. Il présente une sensibilité de 55,6 %, et classe à tort 24 clients à risque comme étant solvables. En parallèle, il rejette également un nombre important de bons clients, ce qui indique une mauvaise gestion du compromis entre les deux types d'erreurs. Cette performance s'explique par la structure même du modèle, qui repose sur des seuils de décision rigides et ne capture pas les interactions complexes entre variables.

La Random Forest améliore sensiblement les résultats de CART, avec une accuracy de 73,5 % et une AUC de 0,764. Elle atteint une sensibilité de 59,3 %, équivalente à celle de la régression logistique, et produit également 22 erreurs critiques. L'agrégation d'arbres permet de réduire la variance et d'obtenir un modèle plus stable, mais sans réelle amélioration sur la détection des clients à risque. Le gain apporté par la non-linéarité reste donc limité dans ce contexte.

Le modèle Adaboost présente un profil très différent. Malgré une accuracy de 74,5 % et une AUC de 0,763, sa sensibilité chute à 42,6 %, ce qui en fait le modèle le moins performant pour détecter les défauts. Il classe

31 clients à risque comme solvables, soit le plus mauvais résultat parmi les modèles étudiés. En revanche, il minimise les faux refus en rejetant moins de clients sains. Ce comportement traduit un biais fort en faveur de la classe majoritaire, ce qui le rend inadapté dans une logique de gestion du risque où la priorité est de limiter les pertes liées aux défauts.

Le modèle LASSO se distingue comme le plus performant dans cette analyse. Avec une accuracy de 75,5 % et une AUC de 0,781, il combine de bonnes performances globales avec la meilleure capacité de détection des clients à risque. Sa sensibilité atteint 61,1 %, et il ne laisse passer que 21 clients à risque, soit le plus faible nombre d'erreurs critiques. Cette performance s'explique par l'utilisation de la pénalisation L1, qui permet de sélectionner les variables les plus pertinentes et de réduire le bruit dans les données. Le modèle parvient ainsi à mieux isoler les profils à risque tout en conservant une bonne stabilité.

Enfin, l'analyse discriminante linéaire (LDA) affiche la meilleure accuracy globale avec 76,0 % et une AUC de 0,776. Toutefois, sa sensibilité reste limitée à 59,3 %, ce qui la place au même niveau que la régression logistique et la Random Forest en termes de détection des clients à risque. Elle génère 22 erreurs critiques, ce qui montre qu'elle n'apporte pas d'amélioration sur le critère principal malgré ses bonnes performances globales. Son efficacité repose sur des hypothèses de structure des données qui ne sont pas parfaitement vérifiées ici.

Ainsi, lorsque l'on classe les modèles selon leur capacité à limiter les erreurs critiques, le LASSO apparaît clairement en tête, suivi par la régression logistique, la Random Forest et la LDA, qui présentent des performances similaires. CART est en retrait, tandis qu'Adaboost se révèle le moins adapté en raison de son incapacité à détecter correctement les clients à risque.

En conclusion, cette analyse montre que le choix du modèle ne doit pas se baser uniquement sur l'accuracy, mais sur sa capacité à minimiser les erreurs les plus coûteuses. Dans ce cadre, le modèle LASSO constitue le meilleur compromis entre performance globale et maîtrise du risque, et apparaît comme le plus pertinent pour une utilisation opérationnelle dans un contexte de décision de crédit.

4 Annexes

4.1 Courbes ROC par méthode

```
plot(ROC_logit, print.auc=TRUE, col="black", print.auc.y = 0.5, main = "Comparaison des Courbes ROC")
plot(ROC_cart, print.auc=TRUE, col="red", print.auc.y = 0.45, add=TRUE)
plot(ROC_RF, print.auc=TRUE, col="blue", print.auc.y = 0.4, add=TRUE)
plot(ROC_adaboost, print.auc=TRUE, col="green", print.auc.y = 0.35, add=TRUE)
plot(ROC_logit_lasso, print.auc=TRUE, col="purple", print.auc.y = 0.3, add=TRUE)
plot(ROC_lda, print.auc=TRUE, col='coral', print.auc.y=0.25, add=TRUE)

# Ajout d'une légende pour identifier chaque courbe
legend("bottomright",
      legend=c("Rég. Logistique", "CART", "RandomForest", "Adaboost", "Lasso", 'LDA'),
      col=c("black", "red", "blue", "green", "purple", "coral"),
      lwd=2)
```

Comparaison des Courbes ROC

